足球預測系統

從直接問 AI 誰會贏，到設計可驗證的預測流程。

WC2026 Football Prediction System • Project narrative



真正的起點：很多人把 LLM 當預言機

真正的問題在於任務從一開始就拆錯。

常見用法

直接問：哪一隊會贏？

要求它「模擬一億次」

把流暢答案當成可下注機率

根本問題

LLM 擅長語言與脈絡，不擅長代替統計模擬

它的文字合理，不代表機率可靠

誰都能問到的答案，市場通常早已定價

第一個判斷：不要把 LLM 假裝成它不擅長的東西；要先重新設計問題。

從「誰會贏」轉成「哪裡被錯估」

把足球預測轉成估計問題：自己的機率估計，是否比市場更有資訊。

LLM：語言機率 → 比較兩組估計 → **市場：賠率機率**

市場是基準

市場本身就是一台成熟的機率機器，賠率可被視為另一組即時估計。

分歧先是查核訊號

模型與市場不同，只能先當查核訊號；沒有可驗證理由，分歧不該被交易。

真正的問題

哪一邊的估計更可信？錯估的來源能不能在事前說清楚、事後驗證？

這一步把專案從「問 AI 答案」改成「管理估計、證據與可驗證性」。

先理解 LLM 適合什麼，再設計系統

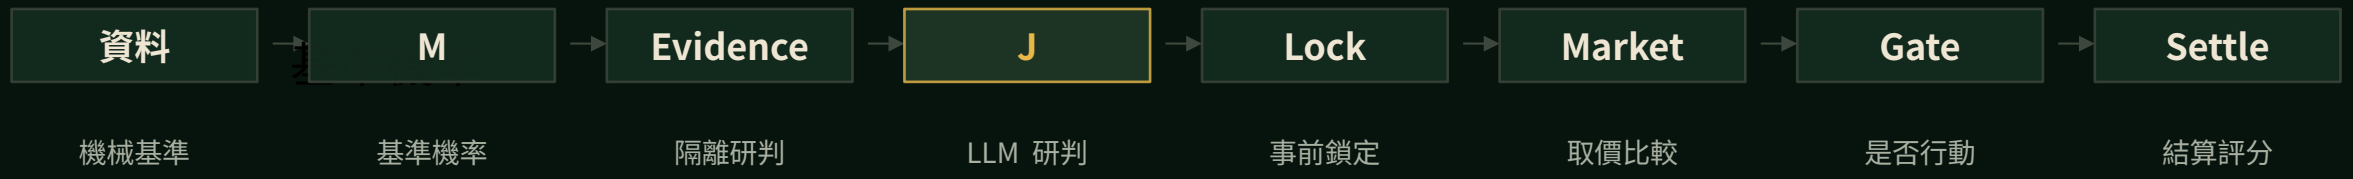
第一版把 prompt 之外的責任，拆給更適合的元件。

機械模型	LLM	程式	人
歷史賽果、 Poisson / Elo 、可重算的基準機率	傷停、陣容、戰術、新聞脈絡等非結構化資訊	EV 、 Kelly 、鎖定、狀態、審計、評分與拒絕規則	風險口徑、策略取捨、是否接受系統建議

設計原則：不叫 LLM 心算賠率、不叫它自己驗證自己，也不把市場答案提前餵給它。

0→1： 先做出能跑完一場比賽的閉環

第一版系統已經從聊天，變成一條可記錄、可回看、可計分的流程。



閉環價值

每個判斷都能追到「當時知道什麼、怎麼估、何時鎖定、結果如何」。後續世界盃實戰因此成為可持續驗證的資料，而非一次性 demo。

世界盃是第一版系統的實戰壓力測試

分析世界盃時已經有系統；真正的演進是在使用中與賽後驗證中持續發生。

實際決策

12

筆決策紀錄

短期結果

9-3

勝率 75%；樣本仍小

完整路徑

R16→Final

從單場到賽事路徑

這是第一版系統首次在時間壓力、資訊變動、賽後結算與市場比較下完整運行。

短期結果提供值得追的訊號；真正重要的是，它讓污染、證據邊界與驗證需求被推進流程。

四強賽時，我們把冠軍算出來了

這頁保留第一版的故事鉤子：系統在決賽前已給出可回查的冠軍機率判斷。

西班牙｜我方 34.6% ・ 市場 22.3% → 最終冠軍：西班牙

四強後鎖定

決賽開踢前，系統已留下原始冠軍機率輸出。

我方估計

34.6%；當時最高冠軍機率。

市場估計

22.3%；市場價格給出的基準較低。

重點不是宣稱必然命中，而是：系統能在事前固定機率、事後回看依據，並把結果納入後續驗證。

真實使用後，問題變得更清楚

第一版能跑，但可靠性不能只靠 LLM 自覺與人工記憶。

資訊污染

市場價格或賽後資訊一旦進入判斷，乾淨估計就不可逆。

自我合理化

LLM 容易把已知結果或市場共識包裝成自己的理由。

難以重現

自由研判有價值，但如果無法重跑與記分，難以比較。

曝險相關

同場、同資訊源或同敘事可能造成重複下注的假分散。

於是問題從「產出答案」升級成「設計一個能約束判斷、保存證據、事後驗證的環境」。

把 LLM 研判拆成可記分的責任層

M 、 J 、完整研判各自擁有不同資訊與自由度；避免同一個模型同時蒐證、判斷、驗證、記帳。

M 機械基準

只吃歷史賽果，產生可重算基準。

證據 證據蒐集

整理傷停、陣容、戰術；不接觸市場價。

J 隔離研判

只讀 M + 證據包 + 凍結 spec ；可重跑、可記分。

研判 完整脈絡

可用完整資訊探索與補充；需對抗查核。

市場 市場共識

估計鎖定後，才進入市場比較。

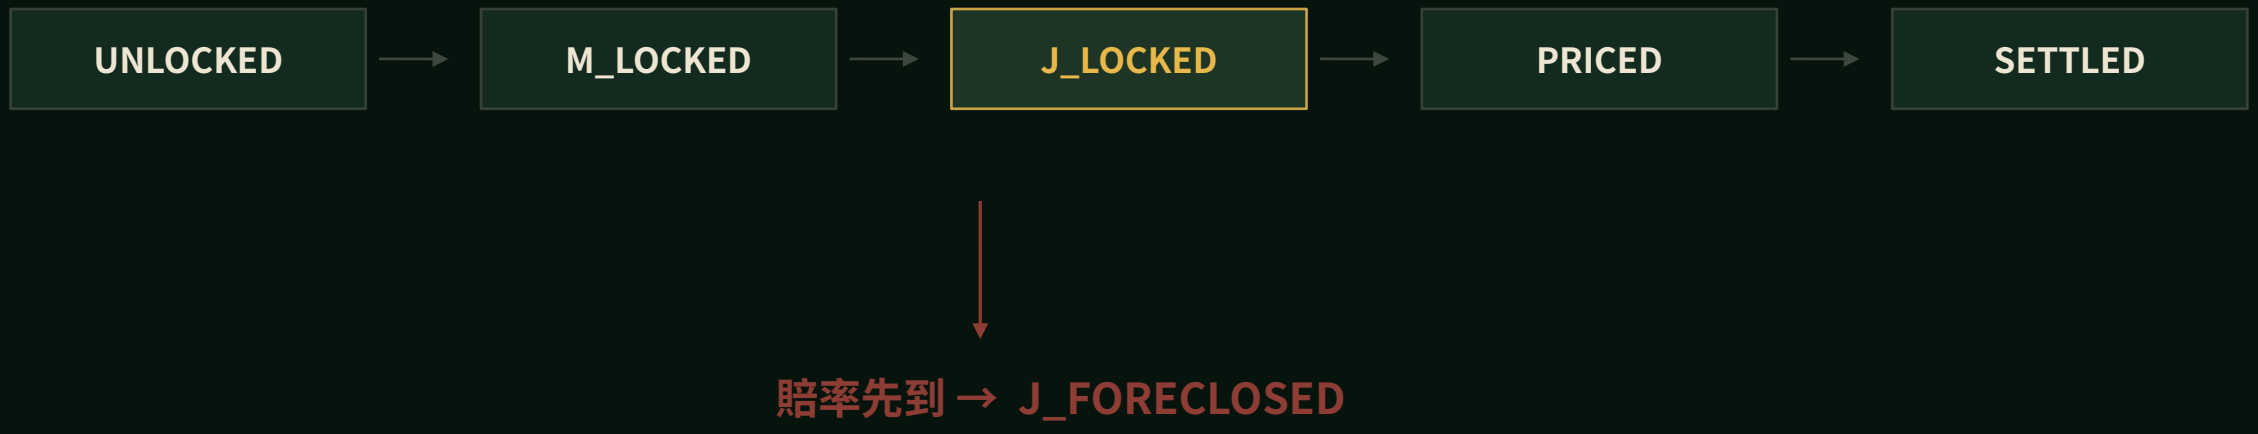
審計 審計紀錄

只新增紀錄，讓狀態可重建。

核心不是增加更多 AI ，而是把 LLM 放進可控制、可比較、可驗證的環境。

污染不可逆，所以順序要由程式保證

市場價一旦先進來，該場的 J 就不再乾淨。



關鍵在於讓不合法順序無法被當成乾淨估計繼續使用。

可靠性靠拒絕動作，不靠模型自覺

高代價錯誤由程式直接擋下，讓規則成為約束，而非提醒。

Lock / Amend	開球後、重複鎖定、沒有新資訊理由 - 拒絕。
Snapshot	未鎖場次不提前取價；先查時鐘，再決定是否呼叫 API 。
Firewall / Schema	市場數字被標記後不可閱讀； coverage 不足不能進研判。
J / SOP	factor 與機率矛盾、缺兌現判準 - 拒絕或標記 UNFINISHED 。
Selftest	同時跑 happy path 與植入錯誤，確認防護真的會擋。

能被機器判定的錯誤，就不應交給 LLM 記憶與自律。

驗證用來允許系統被推翻

短期結果有正向訊號，但真正的系統價值來自固定口徑的樣本外驗證。

OOT 驗證樣本

970

場樣本外驗證

M vs 收盤價

+0.0075

dRPS： 正值＝ M 較差

gap ≥ 10pp

+0.0225

大分歧時差得更多

修正後的定位

970 場樣本外驗證後，模型與市場分歧越大時，錯誤方更常是 M 。因此大 gap 不再被視為自信來源，而是寫進 known_biases ，作為儀器警訊與查核線索。

表面 edge 要先通過市場共識檢查

單一書口看似有巨大 edge；改用 25 家市場共識重新估 fair probability 後， edge 幾乎消失。

模型 vs 單一書口

+27.2%

表面 edge



25 家市場共識後

+0.34%

只剩極小差距

後續主戰場

原本 +27.2% 不能直接視為全市場錯估；用多書口共識重新估 fair probability （去水後公平機率）後，剩餘 edge 只剩 +0.34% 。後續轉向軟盤書口、衍生市場、次級聯賽與 T-75 晚到資訊。

真正留下的是 Agent 系統設計方法

從世界盃預測沉澱出可遷移的工程原則。

可重算的，交給程式	資料、機率、狀態、 EV 、 sizing 、審計與測試。
非結構化理解，交給 LLM	陣容、傷停、戰術、語境、證據歸納與不確定研判。
可靠性，交給環境	資訊邊界、單向狀態、拒絕動作、樣本外驗證與修正迴路。

可靠性來自環境設計：讓模型在可驗證邊界內工作，並讓錯誤能被記錄、拒絕與修正。